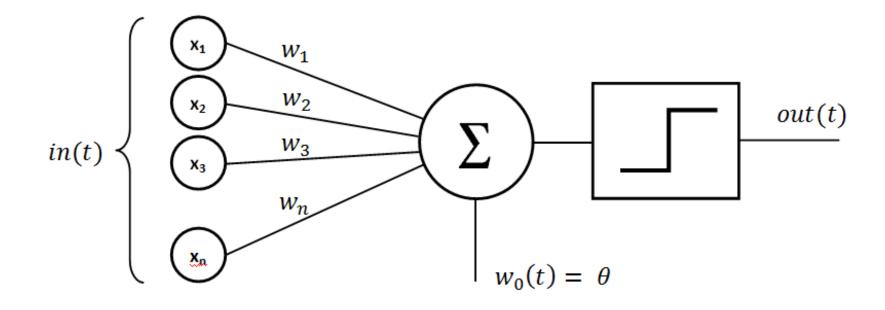


Desenvolvimento de uma rede neural simples para classificação de dados utilizando o conceito de perceptron.

0 que é um perceptron?

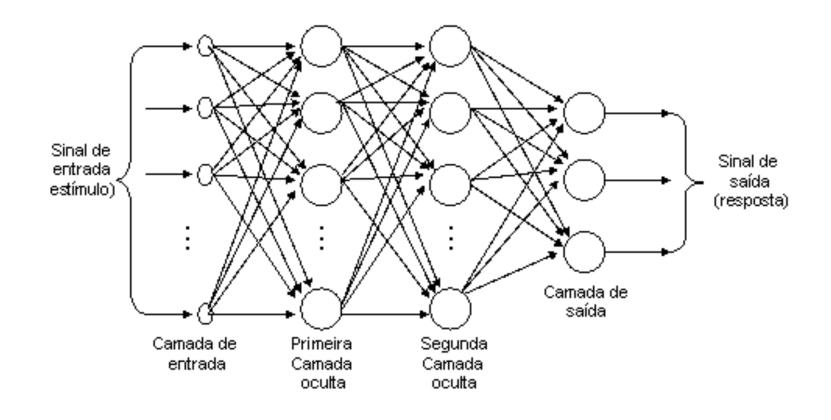




$$y(X) = \varphi\left(W_0 + \sum_{i=1}^n W_i X_i\right)$$

Relação de múltiplas camadas





Treinamento supervisionado da rede



O treinamento supervisionado é aplicado corrigindo os pesos conforme o erro calculado por uma função de perda e uma função de optimização.

$$\Delta w_{j,i}(t) = \eta \delta_j(t) y_i(t)$$

 η é o parâmetro da taxa de aprendizagem, $\delta_j(t)$ é o gradiente local no neurônio j e $y_i(t)$ é o sinal de entrada do neurônio j.

$$\delta_{j}(t) = erro_{j}(t)\varphi_{j}^{'}(v_{j}(t))$$

$$\delta_{j}(t) = \varphi_{j}'(v_{j}(t)) \sum_{k} \delta_{k}(t) W_{k,j}(t)$$

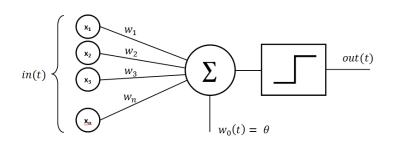
Conjunto de dados usado



| n | ω | φ | ϕ |
|----|-------|--------|--------|
| 1 | 0.411 | 2.108 | -1.258 |
| 2 | 5.566 | 3.051 | 0.612 |
| 3 | 1.624 | 0.438 | 2.511 |
| 4 | 0.213 | 2.812 | -3.571 |
| 5 | 0.074 | 0.810 | 5.122 |
| 6 | 3.561 | 0.579 | 0.023 |
| 7 | 1.222 | -2.830 | 1.113 |
| 8 | 2.667 | -4.701 | -0.782 |
| 9 | 0.316 | 0.865 | 2.367 |
| 10 | 0.251 | 0.357 | 3.157 |

```
using Flux, Plots, Statistics, ProgressMeter
 2
     \omega_{\text{list}} = [0.411, 5.566, 1.624, 0.213, 0.074, 3.561, 1.222, 2.667, 0.316, 0.000]
      \phi_list = [2.108, 3.051, 0.438, 2.812, 0.810, 0.579, -2.830, -4.701, 0.865,
      times = range(0, stop=10, length=1000)
      data = Matrix{Float32}(undef, 200, 1000)
10
      for i = 1:10
11
          for j = 1:20
12
               for p = 1:1000
13
                   \omega = \omega \text{ list[i]}
                   \phi = \phi_{list[j]}
14
                   local t = times[p]
15
                   data[(i-1)*10+j, x] = sin(\omega*t+\phi)
16
17
               end
18
          end
19
      end
```





```
function linear(in, out)
  W = randn(out, in)
  b = randn(out)
  x -> W * x .+ b
end

linear1 = linear(5, 3) # we can access linear1.W etc
linear2 = linear(3, 2)

model(x) = linear2(\sigma.(linear1(x)))
model(rand(5)) # => 2-element vector
```

Documentação do Flux - https://fluxml.ai/Flux.jl/stable/models/basics/



```
layer1 = Dense(10 => 5, σ)
# ...
model(x) = layer3(layer2(layer1(x)))
```

```
using Flux layers = [Dense(10 \Rightarrow 5, \sigma), Dense(5 \Rightarrow 2), softmax] model(x) = foldl((x, m) \Rightarrow m(x), layers, init = x) model(rand(10)) \# \Rightarrow 2-element \ vector
```

Documentação do Flux - https://fluxml.ai/Flux.jl/stable/models/basics/



```
model2 = Chain(
  Dense(10 => 5, σ),
  Dense(5 => 2),
  softmax)

model2(rand(10)) # => 2-element vector
```

Documentação do Flux - https://fluxml.ai/Flux.jl/stable/models/basics/

https://fluxml.ai/Flux.jl/stable/models/layers/



```
model = Chain(
105
                                                                                           n = 1000
           Dense(1000, 500, relu),
106
                                                                                           \varphi = relu
107
           Dense(500, 125, relu),
           Dense(125, 50, relu),
108
                                                                                           n = 500
109
           Dense(50, 10),
                                                                                           \varphi = relu
110
           softmax
111
                                                                                           n = 125
PROBLEMS
            OUTPUT
                       DEBUG CONSOLE
                                          TERMINAL
                                                                                           \varphi = relu
Progress: 100%
Chain(
                                                                                            n = 50
  Dense(1000 => 500, relu),
                                          # 500_500 parameters
  Dense(500 => 125, relu),
                                        # 62 625 parameters
                                                                                           \varphi = relu
  Dense(125 => 50, relu),
                                         # 6 300 parameters
  Dense(50 \Rightarrow 10),
                                          # 510 parameters
  NNlib.softmax,
                                                                                            n = 10
                     # Total: 8 arrays, 569 935 parameters, 2.175 MiB.
                                                                                         \varphi = softmax
```

Tratando a saída da rede



$$\phi(z)_i = \frac{e^{z_i}}{\sum_{k=1}^n e^{z_k}}$$

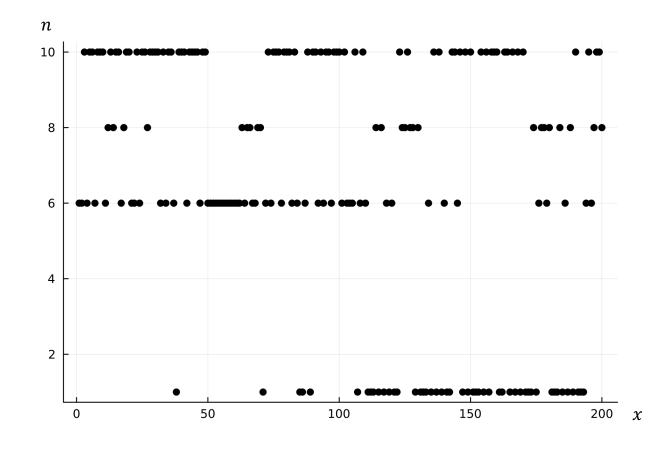
```
10×200 Matrix{Float32}:
            0.098345
0.101192
                       0.158601
                                  0.097925
           0.0826372
0.0878354
                       0.0773421
                                  0.086412
0.0878354
           0.0826372
                       0.0773421
                                  0.086412
0.0878354 0.0826372
                      0.0836591
                                  0.086412
0.0878354 0.0826372
                      0.0773421
                                  0.086412
0.121717
           0.160115
                       0.0773421
                                  0.150008
0.0878354
           0.0826372
                      0.0773421
                                  0.086412
0.0878354 0.0826372
                      0.0950444
                                  0.086412
0.138178
           0.0850244
                      0.0896039
                                  0.0921529
0.111901
           0.160693
                       0.186381
                                  0.141443
```

```
function get_graphdata_from_output(output)
    result = []
    for i = 1:200
       maior = 1
        if (output[2, i] > output[maior, i]) maior = 2 end
        if (output[3, i] > output[maior, i]) maior = 3 end
        if (output[4, i] > output[maior, i]) maior = 4 end
        if (output[5, i] > output[maior, i]) maior = 5 end
        if (output[6, i] > output[maior, i]) maior = 6 end
       if (output[7, i] > output[maior, i]) maior = 7 end
       if (output[8, i] > output[maior, i]) maior = 8 end
        if (output[9, i] > output[maior, i]) maior = 9 end
        if (output[10, i] > output[maior, i]) maior = 10 end
        push!(result, maior)
   end
    return result
end
```

Teste sem treinamento



| n | ω | |
|----|-------|--|
| 1 | 0.411 | |
| 2 | 5.566 | |
| 3 | 1.624 | |
| 4 | 0.213 | |
| 5 | 0.074 | |
| 6 | 3.561 | |
| 7 | 1.222 | |
| 8 | 2.667 | |
| 9 | 0.316 | |
| 10 | 0.251 | |



Treinamento da rede



1. Carregar a estrutura de dados com o Flux.

```
38 desired_values = get_desired_values()
39 loader = Flux.DataLoader((data', desired_values), batchsize = 64, shuffle = true)
```

2. Definir a função de optimização.

```
41 optim = Flux.setup(Adam(0.01), model)
https://fluxml.ai/Flux.jl/stable/training/optimisers/
```

3. Definir a função de perda.

```
42 loss(y_hat,y) = Flux.crossentropy(y_hat, y)
```

https://fluxml.ai/Flux.jl/stable/models/losses/

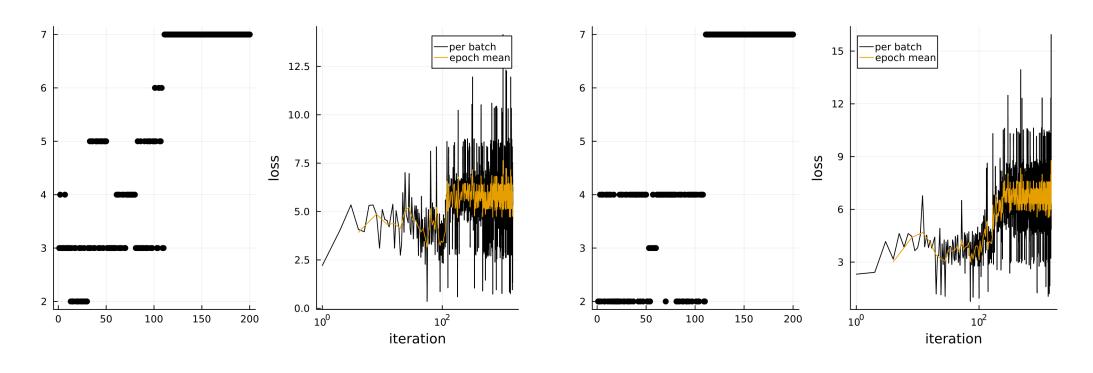
Treinamento da rede



4. Determina uma repetição de treinamento por um período.

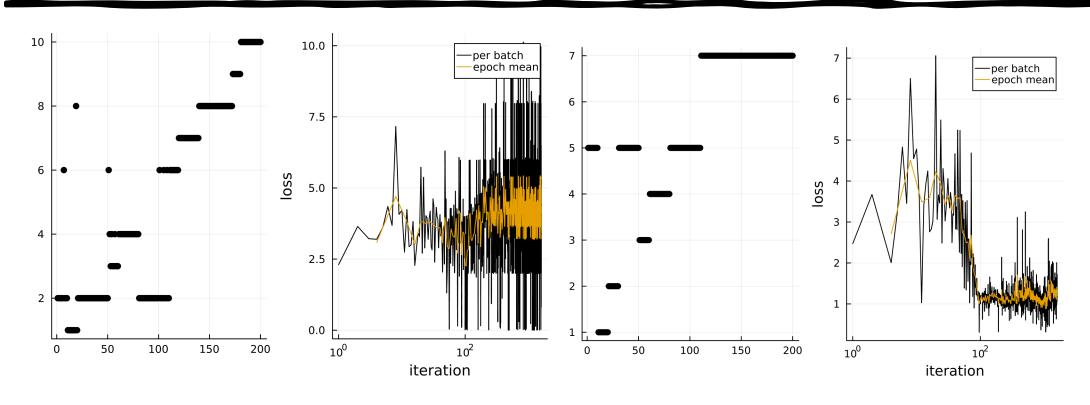
```
losses = []
122
      @showprogress for epochs = 1:200
123
124
          for (x, y) in loader
               loss_r, grads = Flux.withgradient(model) do m
125
                   y_hat = m(x)
126
127
                   loss(y_hat, y)
128
               end
129
               Flux.update!(optim, model, grads[1])
130
               push!(losses, loss_r)
131
          end
132
      end
```





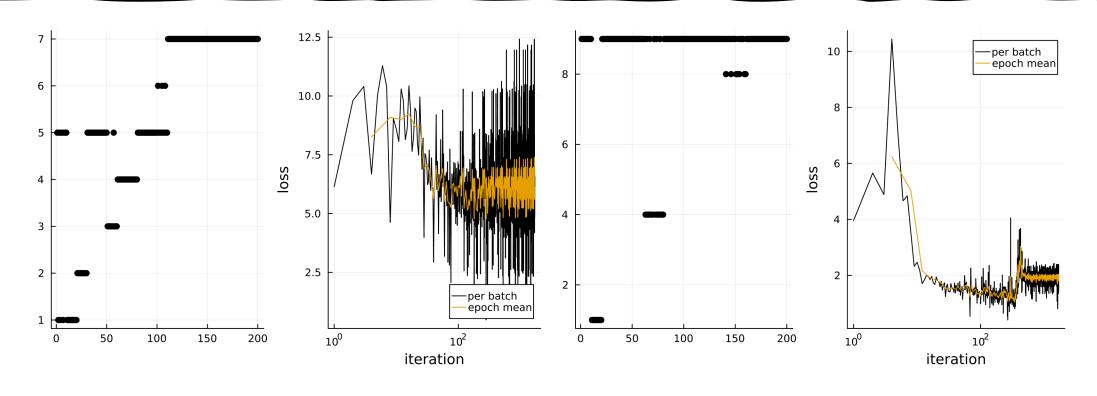
375 épocas





400 épocas





425 épocas

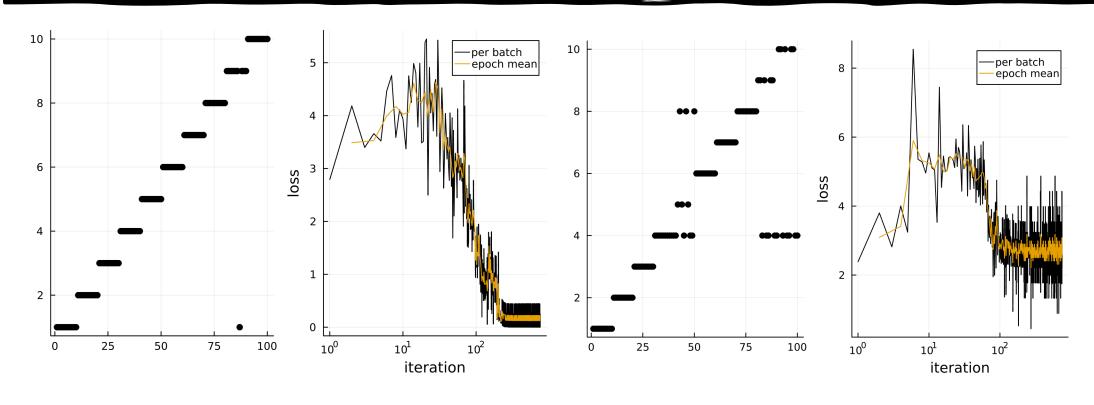


Gerados a partir de uma distribuição normal.

| n | ω | ϕ | ϕ |
|----|----------|--------|--------|
| 1 | 0.411 | 2.108 | -1.258 |
| 2 | 5.566 | 3.051 | 0.612 |
| 3 | 1.624 | 0.438 | 2.511 |
| 4 | 0.213 | 2.812 | -3.571 |
| 5 | 0.074 | 0.810 | 5.122 |
| 6 | 3.561 | 0.579 | 0.023 |
| 7 | 1.222 | -2.830 | 1.113 |
| 8 | 2.667 | -4.701 | -0.782 |
| 9 | 0.316 | 0.865 | 2.367 |
| 10 | 0.251 | 0.357 | 3.157 |

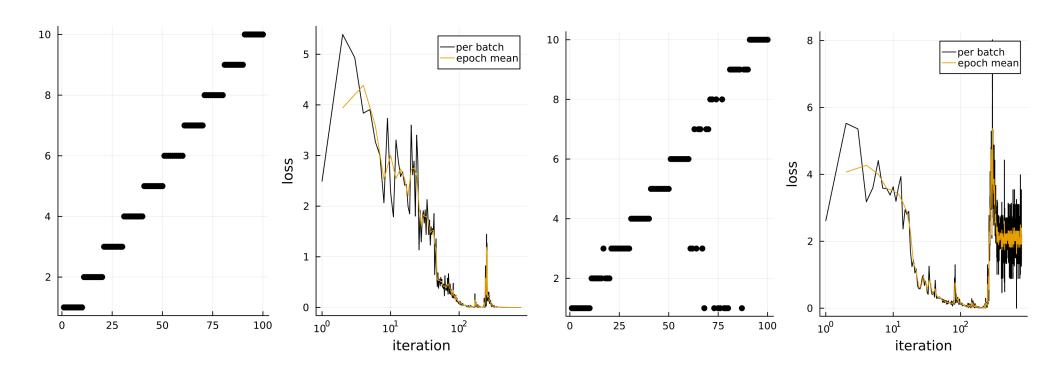
Gerados sem nenhuma relação.





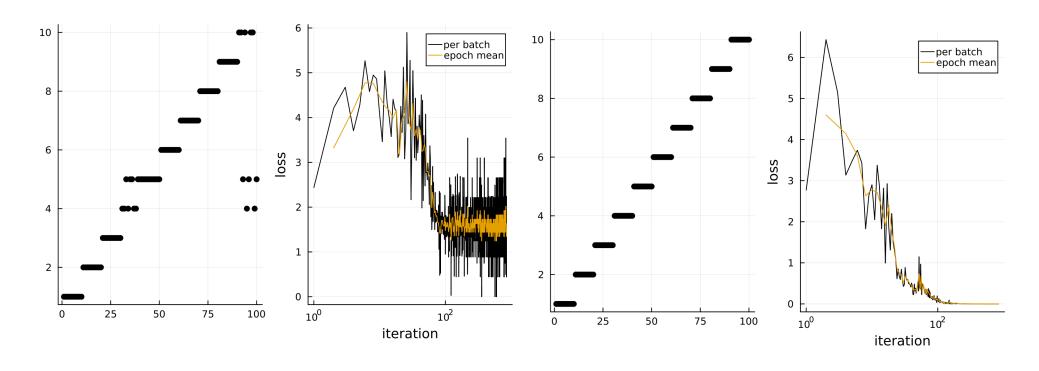
375 épocas





400 épocas





425 épocas

Utilizando a GPU



```
105
        model = Chain(
 106
            Dense(1000, 500, relu),
 107
            Dense(500, 125, relu),
 108
            Dense(125, 50, relu),
 109
            Dense(50, 10),
 110
            softmax
 111
        ) |> gpu
       loader = Flux.DataLoader((data', desired_values), batchsize = 64, shuffle = true) |> gpu
117
134
       out_2 = get_graphdata_from_output(model(data'|>gpu)|>cpu)
135
       graph_2 = scatter(x[1:100], out_2[1:100], legend=false)
   Info: The GPU function is being called but the GPU is not accessible.
 Defaulting back to the CPU. (No action is required if you want to run on the CPU).
 Progress: 100%
⊃ julia>
```

Referências



HAYKIN, Simon. Redes Neurais: princípios e prática, 2ª edição. Editora Bookman, 2001, reimpressão de 2008. ISBN 978-85-7307-718-6

Documentação, Flux, junho/2023. Disponível em: https://fluxml.ai/Flux.jl/stable/



